

INTRODUCTION

Dans ce deuxième notebook, nous avons créé un modèle qui prédit:

- 1. Les rating/notes obtenues par les applications du PlayStore,
- 2. La polarité (positive/négative) d'un commentaire,
- 3. Les catégories d'une application seulement avec son nom.

DataSet trouvé sur Kaggle (*plus de détails ici*). À travers ce notebook vous pourrez voir le cheminement de notre analyse ainsi que son aboutissement : les solutions.

PRESENTATION DES DONNEES

Import

Tout d'abord, on importe :

- les librairies pandas et numpy (permettant d'explorer et de manipuler les datas),
- les librairies matplotlib, plotly et seaborn (afin de réaliser des beaux graphiques),
- la librairie string (pour manipuler des chaines de caractères),
- la librairie google.colab,
- la librairie WordCloud (afin de créer des nuages de tags).

Puis on charge nos datas.

```
# Les librairies utilisées:
import pandas as pd
import matplotlib.pyplot as plt
import plotly.express as px
import numpy as np
import seaborn as sns
import string
import plotly.graph_objects as go
from sklearn.tree import DecisionTreeRegressor ,export graphviz
from sklearn.model selection import train test split
from sklearn.ensemble import RandomForestClassifier
from sklearn import linear_model
from sklearn.metrics import mean squared error, r2 score
from google.colab import drive
from wordcloud import WordCloud, ImageColorGenerator
from IPython.display import Image
from collections import Counter
# Ajout du drive pour avoir accès aux data, ...
drive.mount('/content/drive')
data = pd.read_csv("/content/drive/My Drive/kaggle/playstore/googleplaystore.csv")
data_reviews = pd.read_csv("/content/drive/My Drive/kaggle/playstore/googleplaystore_user_
     Go to this URL in a browser: <a href="https://accounts.google.com/o/oauth2/auth?client_id=947">https://accounts.google.com/o/oauth2/auth?client_id=947</a>
     Enter your authorization code:
     4/1AY0e-g43lTAVTwlbA-ogxc26So8aM9WaW3DghN1j-7a3DtcJtVgOLIssuxO
     Mounted at /content/drive
```

Présentation des caratéristiques des deux data

data

```
10841 non-null object
0 App
1 Category
                 10841 non-null object
2
   Rating
                 9367 non-null float64
3
   Reviews
                 10841 non-null object
4 Size
                 10841 non-null object
5 Installs
                 10841 non-null object
   Type
6
                 10840 non-null object
   Price 10841 non-null object
7
8 Content Rating 10840 non-null object
9 Genres
                 10841 non-null object
10 Last Updated 10841 non-null object
11 Current Ver 10833 non-null object
12 Android Ver
                10838 non-null object
dtypes: float64(1), object(12)
memory usage: 1.1+ MB
```

On peut donc dire qu'il y 13 categories pour definir une app.

```
0. App: Le nom de l'application
```

- 1. Category: La caregorie de l'application
- 2. Rating: La note de l'application
- 3. Reviews: Le nombre de commentaires de l'application
- 4. Size: La taille de l'application
- 5. Installs: Le nombre d'installations
- 6. Type: Gratuit/payant
- 7. Price: Le prix
- 8. Content Rating : Le groupe d'age ciblé par l'application
- 9. Genres : Le genre de l'application (plus précis que catégorie)
- 10. Last Updated : dernière maj
- 11. Current Ver: version actuelle
- 12. Android Ver: version d'android minimum requise

Il y'a 10841 données mais il en manque dans certaines catégories (Rating, Content Rating, Current Ver, Android Ver), il y'en a 9367 exploitable. On doit donc trier la data avant de l'utiliser.

data review

```
Data columns (total 5 columns):

# Column Non-Null Count Dtype
--- 0 App 64295 non-null object
1 Translated_Review 37427 non-null object
2 Sentiment 37432 non-null object
3 Sentiment_Polarity 37432 non-null float64
4 Sentiment_Subjectivity 37432 non-null float64
dtypes: float64(2), object(3)
memory usage: 2.5+ MB
```

On peut donc dire qu'il y 5 categories pour definir un commentaire d'une application.

- 0. App: Le nom de l'application
- 1. Translated_Review: Le commentaire
- 2. Sentiment : S'il parait positif, négatif ou neutre
- 3. Sentiment_Polarity: Son score de polarité (entre -1 et 1 où -1=négatif et 1=positif)
- 4. Sentiment_Subjectivity : Son score de la subjectivité du sentiment

Il y'a 64295 données mais il en manque dans certaines catégories, il y'en a 37427 exploitable. On doit donc trier la data avant de l'utiliser.

Stats rapide

data.describe()

	Rating
count	9367.000000
mean	4.193338
std	0.537431
min	1.000000
25%	4.000000
50%	4.300000
75%	4.500000
max	19.000000

On constate que seulement la donnée Rating est de type numérique.

```
data_reviews.describe()
```

Sentiment_Polarity Sentiment_Subjectivity

count	37432.000000	37432.000000
mean	0.182146	0.492704
std	0.351301	0.259949
min	-1.000000	0.000000
25%	0.000000	0.357143
50%	0.150000	0.514286
75%	0.400000	0.650000

lci on constate que seulement les données Sentiment_Polarity et Sentiment_Subjectivity sont de type numérique.

- TRI DATA

On va ici passer les données intéressantes en valeurs numériques afin qu'elles deviennent exploitables. On fait donc une copie de data dans data_light.

```
total = data.isnull().sum().sort_values(ascending=False)
data_light = data.copy()
data_light.dropna()
data_install = []
data_light.shape
    (10841, 13)
data light.info()
    <class 'pandas.core.frame.DataFrame'>
    RangeIndex: 10841 entries, 0 to 10840
    Data columns (total 13 columns):
     # Column Non-Null Count Dtype
    ---
                      _____
                     10841 non-null object
10841 non-null object
     0 Арр
     1 Category
     2 Rating
                      9367 non-null float64
     3 Reviews
                      10841 non-null object
     4 Size
                      10841 non-null object
     5 Installs 10841 non-null object
       Type 10840 non-null object Price 10841 non-null object
                      10840 non-null object
     6 Type
     7
     8 Content Rating 10840 non-null object
     9 Genres 10841 non-null object
     10 Last Updated 10841 non-null object
```

11 Current Ver

10833 non-null object

```
12 Android Ver 10838 non-null object dtypes: float64(1), object(12) memory usage: 1.1+ MB
```

Type

Size

data_light['Free'] = data_type

```
data light['Size'].unique()
      array(['19M', '14M', '8.7M', '25M', '2.8M', '5.6M', '29M', '33M', '3.1M',
               '28M', '12M', '20M', '21M', '37M', '2.7M', '5.5M', '17M', '39M',
               '31M', '4.2M', '7.0M', '23M', '6.0M', '6.1M', '4.6M', '9.2M',
                                 '24M', 'Varies with device', '9.4M', '15M', '10M',
               '5.2M', '11M',
               '1.2M', '26M', '8.0M', '7.9M', '56M', '57M', '35M', '54M', '201k',
               '3.6M', '5.7M', '8.6M', '2.4M', '27M', '2.5M', '16M', '3.4M',
               '8.9M', '3.9M', '2.9M', '38M', '32M', '5.4M', '18M', '1.1M', '2.2M', '4.5M', '9.8M', '52M', '9.0M', '6.7M', '30M', '2.6M',
               '7.1M', '3.7M', '22M', '7.4M', '6.4M', '3.2M', '8.2M', '9.9M',
               '4.9M', '9.5M', '5.0M', '5.9M', '13M', '73M', '6.8M', '3.5M', '4.0M', '2.3M', '7.2M', '2.1M', '42M', '7.3M', '9.1M', '55M', '23k', '6.5M', '1.5M', '7.5M', '51M', '41M', '48M', '8.5M', '46M',
               '8.3M', '4.3M', '4.7M', '3.3M', '40M', '7.8M', '8.8M', '6.6M',
               '5.1M', '61M', '66M', '79k', '8.4M', '118k', '44M', '695k', '1.6M', '6.2M', '18k', '53M', '1.4M', '3.0M', '5.8M', '3.8M', '9.6M',
               '45M', '63M', '49M', '77M', '4.4M', '4.8M', '70M', '6.9M', '9.3M',
               '10.0M', '8.1M', '36M', '84M', '97M', '2.0M', '1.9M', '1.8M',
               '5.3M', '47M', '556k', '526k', '76M', '7.6M', '59M', '9.7M', '78M', '72M', '43M', '7.7M', '6.3M', '334k', '34M', '93M', '65M', '79M',
               '100M', '58M', '50M', '68M', '64M', '67M', '60M', '94M', '232k',
               '99M', '624k', '95M', '8.5k', '41k', '292k', '11k', '80M', '1.7M',
               '74M', '62M', '69M', '75M', '98M', '85M', '82M', '71M', '86M', '91M', '81M', '92M', '83M', '88M',
                                 '69M', '75M', '98M', '85M', '82M', '96M', '87M',
                                                                              '704k', '862k',
               '899k', '378k', '266k', '375k', '1.3M', '975k', '980k', '4.1M',
               '89M', '696k', '544k', '525k', '920k', '779k', '853k', '720k',
```

```
'713k', '772k', '318k', '58k', '241k', '196k', '857k', '51k',
'953k', '865k', '251k', '930k', '540k', '313k', '746k', '203k',
'26k', '314k', '239k', '371k', '220k', '730k', '756k', '91k', '293k', '17k', '74k', '14k', '317k', '78k', '924k', '902k', '818k',
        '939k', '169k', '45k', '475k', '965k', '90M', '545k', '61k',
'283k', '655k', '714k', '93k', '872k', '121k', '322k', '1.0M'
'976k', '172k', '238k', '549k', '206k', '954k', '444k', '717k'
'210k', '609k', '308k', '705k', '306k', '904k', '473k', '175k'
'350k', '383k', '454k', '421k', '70k', '812k', '442k', '842k',
'417k', '412k', '459k', '478k', '335k', '782k', '721k', '430k'
        , '192k', '200k', '460k', '728k', '496k', '816k', '414k'
'429k',
                   '613k', '243k', '569k', '778k', '683k',
'506k', '887k',
                                                                     '592k',
'319k', '186k', '840k', '647k', '191k', '373k', '437k',
'716k', '585k', '982k', '222k', '219k', '55k', '948k', '323k',
'691k', '511k', '951k', '963k', '25k', '554k', '351k', '27k'
        '208k', '913k', '514k', '551k', '29k', '103k', '898k',
'743k', '116k', '153k', '209k', '353k', '499k', '173k', '597k',
'809k', '122k', '411k', '400k', '801k', '787k', '237k', '50k',
         '986k', '97k',
        , '986k', '97k', '516k', '837k', '780k', '961k', '269k'
'498k', '600k', '749k', '642k', '881k', '72k', '656k',
                                                          '961k', '269k',
'601k', '221k', '228k', '108k', '940k', '176k', '33k', '663k',
'34k', '942k', '259k', '164k', '458k', '245k', '629k', '28k', '288k', '775k', '785k', '636k', '916k', '994k', '309k', '485k' '914k', '903k', '608k', '500k', '54k', '562k', '847k', '957k',
'688k', '811k', '270k', '48k', '329k', '523k', '921k', '874k'
        , '784k', '280k', '24k', '518k', '754k', '892k',
                                                                   '154k'
'981k',
'860k', '364k', '387k', '626k', '161k', '879k', '39k', '970k',
'170k', '141k', '160k', '144k', '143k', '190k', '376k', '193k'
'246k', '73k', '658k', '992k', '253k', '420k', '404k', '1,000+'
'470k', '226k', '240k', '89k', '234k', '257k', '861k', '467k',
                                                         '861k',
'157k', '44k', '676k', '67k', '552k', '885k', '1020k', '582k',
'619k'], dtype=object)
```

La donnée Size est de type Object, on va modifier ses valeurs de la sorte : '10k' => 10000.

```
unite = ['Varies with device', 'M','+', 'k']
for i in range(10841):
      nvUni = data light.Size[i][-1]
      if (((nvUni in unite)==0) and (data light.Size[i] != 'Varies with device')):
        unite.append(data light.Size[i])
print(unite)
     ['Varies with device', 'M', '+', 'k']
data size = []
for i in range(10841):
    if (data_light.Size[i]=='Varies with devices'):
      data size.append('NaN')
   elif (data light.Size[i][-1]=='k'):
      taille = len(data light.Size[i])
      Str valeur = data light.Size[i][0:taille-1]
      valeur = float(Str valeur)
      valeur = valeur*1000
```

```
data_size.append(valeur)

elif (data_light.Size[i][-1]=='M'):
    taille = len(data_light.Size[i])
    Str_valeur = data_light.Size[i][0:taille-1]
    valeur = float(Str_valeur)
    valeur = valeur*1000000
    data_size.append(valeur)

else:
    taille = len(data_light.Size[i])
    data_light.Size[i][0:taille-1]
    data_size.append(float(Str_valeur))

data_light['Size'] = data_size

data_light
```

	Арр	Category	Rating	Reviews	Size	Installs
0	Photo Editor & Candy Camera & Grid & ScrapBook	ART_AND_DESIGN	4.1	159	19000000.0	10,000+
1	Coloring book moana	ART_AND_DESIGN	3.9	967	14000000.0	500,000+
	U Launcher Lite –					

Installs

La donnée Installs est de type Object, on va donc la convertir en réel ("float") après avoir supprimé les ',' et les '+'. On va la modifier de la sorte : '5,000+' => 5000.

```
Syaya
     10026
                                         15
                                                            38 53000000 0
                                                                                 5 000+
# On remplace ',' par '' pour pouvoir convertir plus simplement par la suite.
data_light['Installs'] = data_light['Installs'].replace(',','',regex=True)
# On supprime le '+' de chaque donnée ou on la remplace par 'NaN', puis on la convertie er
for inst in range(10841):
 if (data light.Installs[inst][-1] == '+'):
   taille = len(data_light.Installs[inst])
    str valeur = data light.Installs[inst][0:taille-1]
   data light.Installs[inst] = str valeur
 else:
    data light.Installs[inst] = 'NaN'
data light['Installs'] = data light['Installs'].astype(float)
data light.describe()
```

/usr/local/lib/python3.6/dist-packages/ipykernel_launcher.py:9: SettingWithCopyWarni

A value is trying to be set on a copy of a slice from a DataFrame

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/u

/usr/local/lib/python3.6/dist-packages/ipykernel_launcher.py:11: SettingWithCopyWarn

A value is trying to be set on a copy of a slice from a DataFrame

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/u

	Rating	Size	Installs	Free
count	9367.000000	1.084100e+04	1.083900e+04	10841.000000
mean	4.193338	1.815042e+07	1.546577e+07	0.926022
std	0.537431	2.217026e+07	8.503315e+07	0.261748
min	1.000000	1.000000e+00	0.000000e+00	0.000000

Reviews

data_light['Reviews'].unique()

array(['159', '967', '87510', ..., '603', '1195', '398307'], dtype=object)

Cette donnée est de type Object, on va donc la convertir en entier ("int").

La commande de conversion nous renvoie une erreur expliquant qu'il y a une donnée "3.0M" (signifiant 3 Millions) donc impossible de la convertir en int.

Donc on détermine la position de cette ligne puis on la remplace.

data_light[data_light['Reviews'].str.contains('M')]

	Арр	Category	Rating	Reviews	Size	Installs	Туре	Price	Conte Rati
10472	Life Made WI-Fi Touchscreen Photo Frame	1.9	19.0	3.0M	404.0	NaN	0	Everyone	Na

Le "M" est à la position 10472. On voit que pour cette ligne, toutes les données ont été décalées à partir de la catégorie. On va donc remplacer les données qui nous intéressent manuellement de la sorte : '3.0M' => 3000000.

```
data_light['Category'].loc[10472] = "NaN"
data_light['Rating'].loc[10472] = 1.9
data_light['Reviews'].loc[10472] = 19
data_light['Size'].loc[10472] = 3000000
data_light['Installs'].loc[10472] = 404
data_light['Type'].loc[10472] = "NaN"
data_light['Price'].loc[10472] = 0
data_light['Reviews'] = data_light['Reviews'].astype(int)
data_light.describe()
```

/usr/local/lib/python3.6/dist-packages/pandas/core/indexing.py:670: SettingWithCopyW

A value is trying to be set on a copy of a slice from a DataFrame

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/u

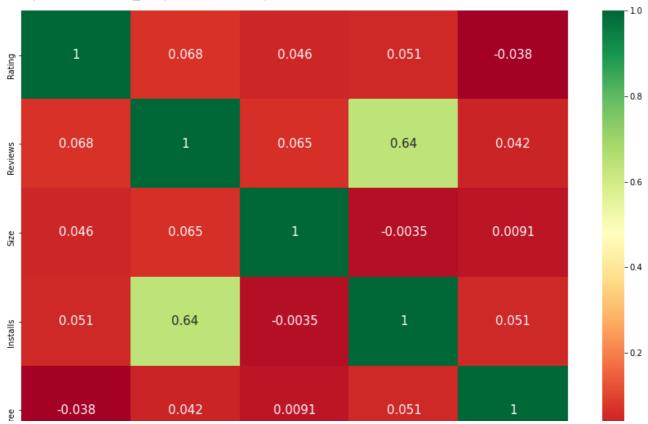
	Rating	Reviews	Size	Installs	Free
count	9367.000000	1.084100e+04	1.084100e+04	1.084000e+04	10841.000000
mean	4.191513	4.441119e+05	1.815070e+07	1.546434e+07	0.926022
std	0.515735	2.927629e+06	2.217006e+07	8.502936e+07	0.261748
min	1.000000	0.000000e+00	1.000000e+00	0.000000e+00	0.000000
25%	4.000000	3.800000e+01	2.600000e+06	1.000000e+03	1.000000
50%	4.300000	2.094000e+03	9.200000e+06	1.000000e+05	1.000000
75%	4.500000	5.476800e+04	2.600000e+07	5.000000e+06	1.000000
max	5.000000	7.815831e+07	1.000000e+08	1.000000e+09	1.000000

On a maintenant les données Rating, Reviews, Size, Installs et Free exploitables car en valeurs numériques.

- ANALYSE DATA

```
plt.figure(figsize=(15, 10))
sns.heatmap(data light.corr(), annot=True, cmap="RdYlGn", annot kws={"size":15})
```

<matplotlib.axes._subplots.AxesSubplot at 0x7f665e13b9e8>



Reviews

On s'intéresse maintenant aux commentaires de chaque application.

data_light[data_light.Reviews > 5000000].describe()

	Rating	Reviews	Size	Installs	Free
count	230.000000	2.300000e+02	2.300000e+02	2.300000e+02	230.0
mean	4.436522	1.368023e+07	3.040002e+07	3.297826e+08	1.0
std	0.158227	1.457751e+07	3.726226e+07	3.347977e+08	0.0
min	3.800000	5.091448e+06	1.500000e+00	5.000000e+07	1.0
25%	4.400000	6.198642e+06	1.800000e+01	1.000000e+08	1.0
50%	4.500000	8.154614e+06	9.800000e+01	1.000000e+08	1.0
75%	4.500000	1.282210e+07	6.300000e+07	5.000000e+08	1.0
max	4.700000	7.815831e+07	1.000000e+08	1.000000e+09	1.0

On constate ici qu'il y a 230 applications de plus de 5M de commentaires, avec une moyenne de 13.6M de commentaires.

data_light[data_light.Reviews <= 5000000].describe()</pre>

	Rating	Reviews	Size	Installs	Free
count	9137.000000	1.061100e+04	1.061100e+04	1.061000e+04	10611.000000
mean	4.185345	1.572109e+05	1.788519e+07	8.650654e+06	0.924418
std	0.520098	5.386233e+05	2.165352e+07	5.271562e+07	0.264340
min	1.000000	0.000000e+00	1.000000e+00	0.000000e+00	0.000000
25%	4.000000	3.400000e+01	2.700000e+06	1.000000e+03	1.000000
50%	4.300000	1.802000e+03	9.200000e+06	1.000000e+05	1.000000
75%	4.500000	4.508250e+04	2.500000e+07	1.000000e+06	1.000000
max	5.000000	4.972230e+06	1.000000e+08	1.000000e+09	1.000000

On constate ici qu'il y a 10611 applications de moins de 5M de commentaires, avec une moyenne de 157.5k commentaires.

Diagramme

On regarde de plus la distribution des reviews grâce à un KDE plot.

```
plt.figure(figsize=(15, 10))
kde = sns.kdeplot(data_light.Reviews, color="grey", shade = True)
kde.set_xlabel("Reviews")
kde.set_ylabel("Fréquence")
plt.title('Distribution des commentaires',size = 25, color='grey')
```

Text(0.5, 1.0, 'Distribution des commentaires')



Ce graphe illustre les résultats trouvés ci-dessus, c'est-à-dire qu'il y a énormément d'applications qui ont peu de commentaires.

3-

Installs et Reviews

On constate que les 2 variables les plus corrélées sont Installs et Reviews à hauteur de 0.64.

Cela s'expliquerait par le fait que plus il y a d'installations, plus il y a d'utilisateurs qui ont essayé l'application et qui laissent un commentaire. Egalement, cela signifierait que les utilisateurs ont tendance à télécharger des applications avec beaucoup de commentaires.

Diagramme

```
plt.figure(figsize=(15, 10))
sns.stripplot(x=data_light['Installs'], y=data_light['Reviews'])
```

<matplotlib.axes. subplots.AxesSubplot at 0x7f66542e86d8>



On constate donc que l'hypothèse est vérifiée : Plus une application a d'installations, plus elle a de commentaires.

Donc avoir beaucoup de commentaires sur une application peut faire augmenter le nombre d'installations.

Reviews et Rating

On analysera ici la note de l'application en fonction du nombre de commentaires.

data_light['Rating'].describe()

```
9367.000000
count
mean
            4.191513
std
            0.515735
min
            1.000000
25%
            4.000000
50%
            4.300000
75%
            4.500000
            5.000000
max
```

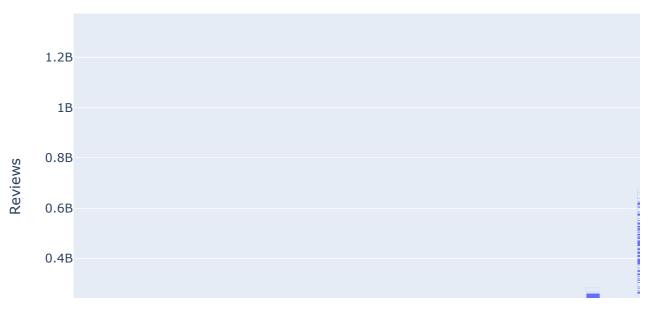
Name: Rating, dtype: float64

Pour la donnée Rating, les notes vont de 1 à 5 avec une moyenne de 4.19.

Diagramme

```
\label{eq:second}  \mbox{fig = px.bar(data\_light, x='Rating', y='Reviews', title="Nombre de Reviews en fonction de fig.show()}
```

Nombre de Reviews en fonction de la note Rating



۷.٥

٥.٥

Il semblerait qu'une application avec beaucoup de commentaires ait une bonne note (environ 4.5).

Installs et Rating

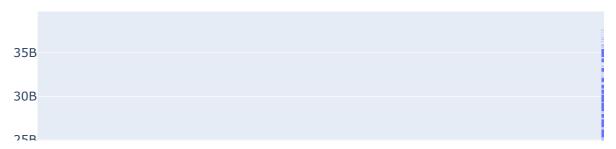
On va regarder ici si le nombre d'installations a un lien avec la note de l'application.

1.5

Diagramme

fig = px.bar(data_light, x='Rating', y='Installs', title="Nombre d'Installs en fonction de fig.show()

Nombre d'Installs en fonction de la note Rating



Comme précédemment, les applications beaucoup installées et donc connues sont celles avec une bonne note (environ 4.3).

Category

C'est ensuite les catégories qui nous intéressent, c'est-à-dire lesquelles sont les plus fréquentes.

1 1.0 2 2.0 3 3.0 4

Analyse/Tri

```
#g = sns.countplot(x="Category",data=data_light, palette = "Set1")
#g.set_xticklabels(g.get_xticklabels(), rotation=90, ha="right")
#plt.title('Count of app in each category',size = 20)
```

data_light.Category

```
0
              ART AND DESIGN
1
              ART AND DESIGN
2
              ART_AND_DESIGN
3
              ART AND DESIGN
              ART_AND_DESIGN
10836
                       FAMILY
10837
                       FAMILY
                     MEDICAL
10838
10839
         BOOKS AND REFERENCE
10840
                   LIFESTYLE
Name: Category, Length: 10841, dtype: object
```

D'abord, on crée une liste contenant chaque catégorie une seule fois.

```
category=[]
for cat in data_light.Category:
   if cat not in category:
      category.append(cat)
```

```
del category[-1]
print(category)
    ['ART_AND_DESIGN', 'AUTO_AND_VEHICLES', 'BEAUTY', 'BOOKS_AND_REFERENCE', 'BUSINESS',
```

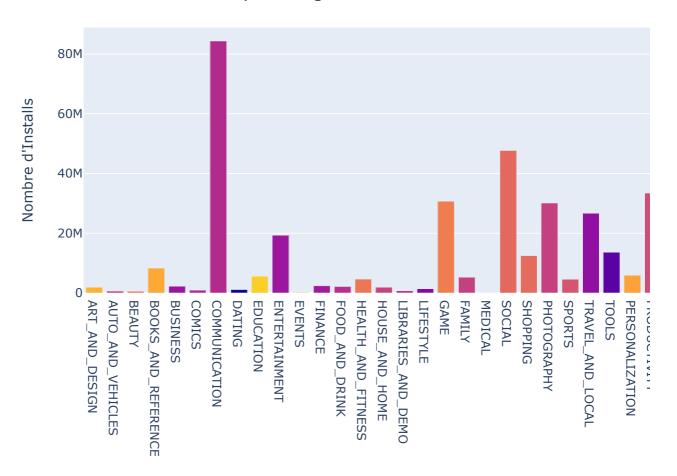
Puis pour chaque catégorie, on crée une nouvelle liste avec son nombre d'applications.

```
means=[]
nbrCat=[]
CatAllRating=[]
def Cat(catego):
  CatAllRating.append([])
  nb=0
  rate=0
  for j in range(10841):
    if ((catego == data_light.Category[j]) and (np.isnan(data_light.Rating[j]) == False)):
      CatAllRating[-1].append(data_light.Rating[j])
      rate = rate + data_light.Rating[j]
  means.append(rate/nb)
  nbrCat.append(nb)
for i in category:
 A=Cat(i)
nbrCatIn=[]
def CatIns(catego):
  nb=0
  a=0
  for j in range(10841):
    if ((catego == data_light.Category[j]) and (np.isnan(data_light.Installs[j]) == False)
     nb = nb + data_light.Installs[j]
      a=a+1
  nbrCatIn.append(nb/a)
for i in category:
 A=CatIns(i)
```

Diagramme

```
fig = px.bar(x=category, y=nbrCatIn, hover_data=[means], color=means)
fig.update_layout(title="Nombre d'installations par catégorie", xaxis_title="Catégories",
fig.show()
```

Nombre d'installations par catégorie



Les applications de la catégorie 'Communication' sont les plus installées.

fig = px.bar(x=category, y=nbrCat, hover_data=[means], color=means)
fig.update_layout(title="Nombre d'applications par catégorie", xaxis_title="Catégories", y
fig.show()

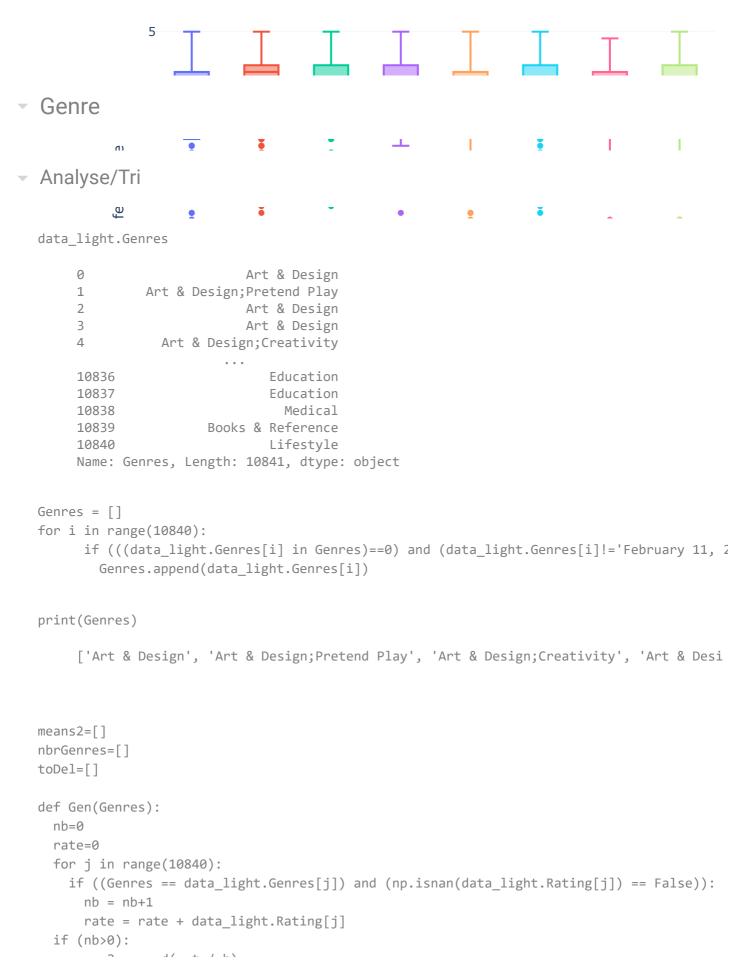
Nombre d'applications par catégorie



Les catégories 'Family' et 'Game' sont les plus fréquentes sur Playstore.

```
fig = go.Figure()
fig.add_trace(go.Box(y=CatAllRating[6], name='COMMUNICATION'))
fig.add_trace(go.Box(y=CatAllRating[17], name='GAME'))
fig.add_trace(go.Box(y=CatAllRating[20], name='SOCIAL'))
fig.add_trace(go.Box(y=CatAllRating[22], name='PHOTOGRAPHY'))
fig.add_trace(go.Box(y=CatAllRating[24], name='TRAVEL_AND_LOCAL'))
fig.add_trace(go.Box(y=CatAllRating[27], name='PRODUCTIVITY'))
fig.add_trace(go.Box(y=CatAllRating[30], name='VIDEO_PLAYERS'))
fig.add_trace(go.Box(y=CatAllRating[31], name='NEWS_AND_MAGAZINES'))
fig.update_layout(
    title='La répartitions des rating des 8 catégories les plus fréquentes',
   yaxis_title='difference de Rating',
   xaxis_title='Category',
      paper_bgcolor='rgb(233,233,233)',
    plot_bgcolor='rgb(233,233,233)',
)
fig.show()
```

La répartitions des rating des 8 catégories les plus fréquentes



```
means2.append(rate/nb)
  nbrGenres.append(nb)
  else:
     toDel.append(Genres)

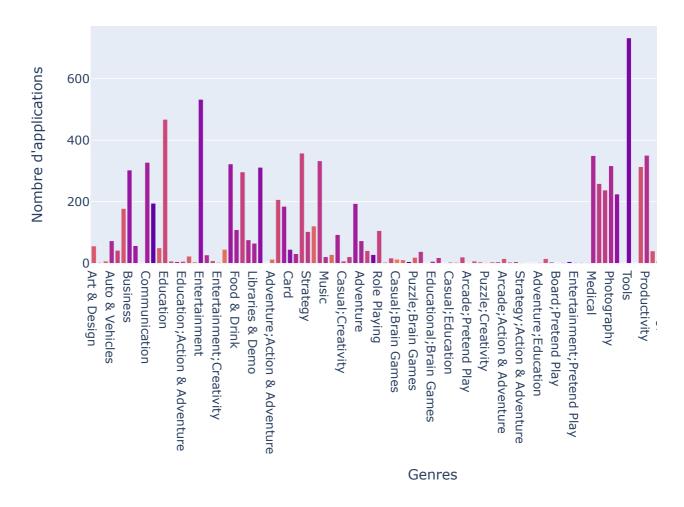
for i in Genres:
    Gen(i)

for i in toDel:
    del Genres[Genres.index(i)]
```

Diagramme

```
fig = px.bar(x=Genres, y=nbrGenres, hover_data=[means2], color=means2)
fig.update_layout(title="Nombre d'applications par genre", xaxis_title="Genres", yaxis_tit
fig.show()
```

Nombre d'applications par genre



Les genres les plus fréquents sont 'Tools' (outils), 'Entertainment' (divertissement) et 'Education'.

Size

Analyse/Tri

On s'intéresse ensuite à la taille des applications.

```
data_light.Size
             19000000.0
     1
             14000000.0
              8700000.0
     3
             25000000.0
              2800000.0
                 . . .
     10836 53000000.0
     10837
            3600000.0
             9500000.0
     10838
               9.5
     10839
     10840 19000000.0
     Name: Size, Length: 10841, dtype: float64
size = []
for i in range(10841):
     if ((data_light.Size[i] in size)==0):
        size.append(data_light.Size[i])
len(size)
     655
means3=[]
nbrSize=[]
def Siz(size):
  nb=0
  rate=0
  for j in range(10841):
   if (size == data_light.Size[j]):
     nb = nb+1
     rate = rate + data_light.Rating[j]
  means3.append(rate/nb)
  nbrSize.append(nb)
for i in size:
  Siz(i)
```

Diagramme

fig.update_layout(title="Nombre d'applications par rapport à leur taille", xaxis_title="Si
fig.show()

Nombre d'applications par rapport à leur taille

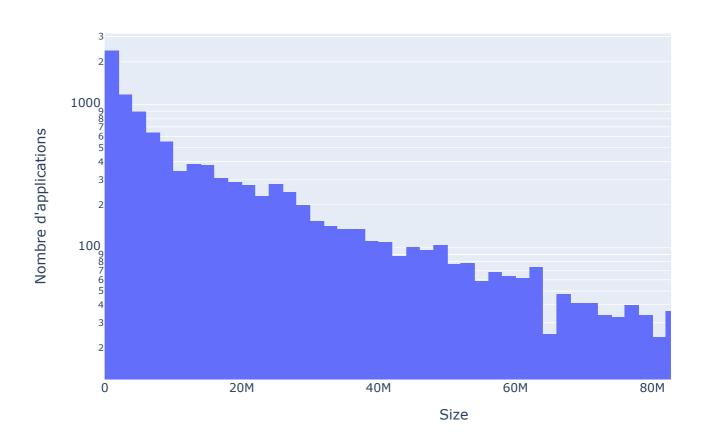
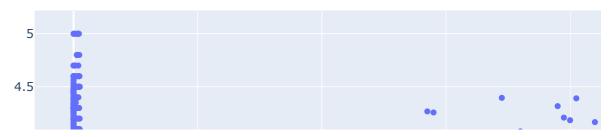


fig = px.scatter(x=size, y=means3)
fig.show()



En effet, il y a plus d'applications de taille faible (<40M).

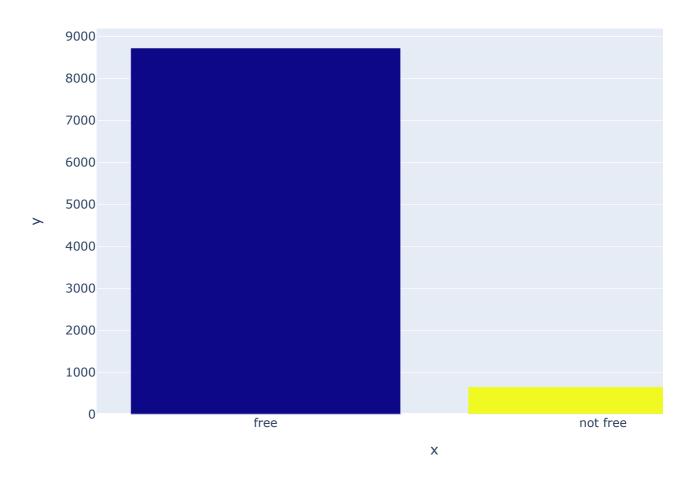
Free

Analyse/Tri

On regarde maintenant s'il y a plus d'applications gratuites ou payantes.

```
nbrf=0
ratef=0
nbr=0
rate=0
FreeAllRating=[]
NotFreeAllRating=[]
for i in range(10841):
  if (data_light.Free[i]==1 and (np.isnan(data_light.Rating[i]) == False) and (data_light.
    FreeAllRating.append(data_light.Rating[i])
    nbrf=nbrf+1
    ratef=ratef+data_light.Rating[i]
  elif ((np.isnan(data_light.Rating[i]) == False) and data_light.Rating[i]<6 ):</pre>
    NotFreeAllRating.append(data_light.Rating[i])
    nbr=nbr+1
    rate = rate+data light.Rating[i]
rate=rate/nbr
ratef=ratef/nbrf
means4=[ratef, rate]
```

Diagramme



Ce graphique nous montre que les applications sont majoritairement gratuites sur Playstore.

```
fig = go.Figure()
fig.add_trace(go.Box(y=FreeAllRating, name = 'Free', marker_color='#FF4136'))
fig.add_trace(go.Box(y=NotFreeAllRating, name = 'Not Free', marker_color='royalblue'))
fig.update_layout(
    title='La répartitions des rating Free/Not Free',
    yaxis_title='difference de Rating'
)
```

La répartitions des rating Free/Not Free



Linear regression

```
# tri data
data_reg = data_light.copy()
data_reg.Category[10472] = data_reg.Category[1]

for i in range(10840):
    if ((np.isnan(data_reg.Rating[i]) == True) or (np.isnan(data_reg.Installs[i]) == True)
    or (np.isnan(data_reg.Size[i]) == True) or (np.isnan(data_reg.Reviews[i] == True))):
    data_reg.drop(i,0,inplace=True)

/usr/local/lib/python3.6/dist-packages/ipykernel_launcher.py:3: SettingWithCopyWarni

A value is trying to be set on a copy of a slice from a DataFrame

See the caveats in the documentation: <a href="https://pandas.pydata.org/pandas-docs/stable/u">https://pandas.pydata.org/pandas-docs/stable/u</a>
```

```
cat2=[]

for i in data_reg.Category:
    for j in category:
        if (i == j):
            cat2.append(category.index(j))

data_reg['IndexCat'] = cat2
```

On essaye de prédire Rating avec Installs.

```
x_train, x_test, y_train, y_test = train_test_split(X, Y, test_size=0.25, random_state=1)
reg = linear_model.LinearRegression()
reg.fit(x_train, y_train)
predictX = reg.predict(x_test)

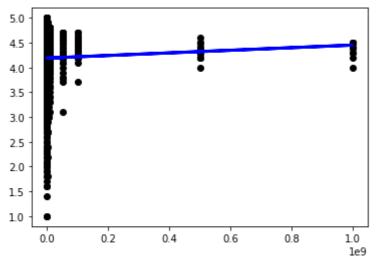
mse = mean_squared_error(y_test, predictX)
r2 = r2_score(y_test,predictX)

print('Mean squared error: ', mse)
print('Coefficient of determination:', r2)

plt.scatter(x_test.Installs, y_test, color='black')
plt.plot(x_test.Installs, predictX, color='blue', linewidth=3)

plt.show()
```

Mean squared error: 0.2707011878223813 Coefficient of determination: 0.0033790247490301795



Random forest

On essaye de prédire Rating avec Installs, Reviews, Size, IndexCat (les catégorie) et enfin Free.

	Reviews	Size	Installs	Free	IndexCat
0	0.519224	0.017318	0.378279	0.018829	0.066349

0.13222025695568662

export_graphviz(clf, out_file='treeGooglePlayStore.dot',feature_names = XForest.columns.tc
!dot -Tpng treeGooglePlayStore.dot -o treeGooglePlayStore.png
Image(filename = 'treeGooglePlayStore.png')



Conclusion

D'après l'analyse des données ci-dessus, on constate que :

- Plus une application a de commentaires, plus elle est installée,
- Une application avec beaucoup de commentaires ou beaucoup d'installations a une bonne note (environ 4.5),
- Les catégories les plus fréquentes sur Playstore sont 'Family' et 'Game',
- Mais celles avec le plus d'installations sont 'Communication' et 'Social'.
- Les genres les plus fréquents sont 'Tools', 'Entertainment' et 'Education',
- La taille des applications est généralement faible (< 40M),
- Les applications sont gratuites en général.

REVIEWS

Dans cette partie, nous allons nous intéresser à la positivité ou non des commentaires.

Imports

D'abord, on charge un fichier contenant des mots avec leur vecteur associé.

```
embedding_dict={}
with open('/content/drive/My Drive/kaggle/playstore/Dictionnaire_mot&Vecteur.txt','r') as
   for line in f:
      values=line.split()
      word=values[0]
      vectors=np.asarray(values[1:],'float32')
      embedding dict[word]=vectors
```

```
f.close()
len(embedding_dict)
400000
```

Ce fichier contient 400000 mots.

Puis on charge un fichier contenant une liste de mots negatifs, puis un fichier contenant une liste de mots positifs trouver sur la plateforme KAGGLE.

```
List_Negative_Words=[]
with open('/content/drive/My Drive/kaggle/playstore/negative-words.txt','r') as f:
   for line in f:
     # word=line.split()
     line = line[:-1]
     for word in embedding dict:
       if (line==word):
          List_Negative_Words.append(line) #on vérifie que le mot negatif est bien parmi l
          # print(line)
f.close()
List_Positive_Words=[]
with open('/content/drive/My Drive/kaggle/playstore/positive-words.txt','r') as f:
   for line in f:
      # word=line.split()
     line = line[:-1]
     for word in embedding_dict:
       if (line==word):
         List Positive Words.append(line) #on vérifie que le mot positif est bien parmi l
          # print(line)
f.close()
print(List_Positive_Words)
     ['abound', 'abounds', 'abundance', 'abundant', 'accessible', 'acclaim', 'acclaimed',
data reviews.head()
```

	App	Translated_Review	Sentiment	Sentiment_Polarity	Sentiment_Subjectivity
0	10 Best Foods for	l like eat delicious food. That's I'm cooking	Positive	1.00	0.533333
len(data	_reviews	.Sentiment_Polarity	y)		
642	95				
	for	regular basis			
data_rev	iews_lig	ght=data_reviews.cop ght=data_reviews_li ght=data_reviews_li	ght.drop(['		ectivity','Sentiment'], a
/	FOORS	INSIN	INSIN	ияи	ияи
data_rev	iews_li	ght.head()			

	Translated_Review	Sentiment_Polarity
0	I like eat delicious food. That's I'm cooking	1.00
1	This help eating healthy exercise regular basis	0.25
3	Works great especially going grocery store	0.40
4	Best idea us	1.00
5	Best way	1.00

Les commentaires contenus dans la donnée 'Translated_Review' ne sont pas unifiés (ils ont de la ponctuation, des majuscules). On va les mettre en forme afin de les analyser facilement par la suite.

```
def remove_punct(text):
    table=str.maketrans('','',string.punctuation)
    return text.translate(table)

example="I am simon #des ..... foulard+"
example=remove_punct(example)
print(example)
example.split()

I am simon des foulard
['I', 'am', 'simon', 'des', 'foulard']
```

On voit que la fonction remove_punct permet d'enlever la ponctuation d'une chaine de caractères.

```
mot="Bonjour LES BarIsTa"
mot=mot.lower() #pour mettre en minuscule
print(mot)
```

bonjour les barista

data_reviews_light['Translated_Review']=data_reviews_light['Translated_Review'].apply(lamble #on enleve la ponctuation de tous les commentaires

for comment in data_reviews_light['Translated_Review']:
 comment=comment.lower() #on met en minuscule
 print(comment.split())

Streaming output truncated to the last 5000 lines.

```
['great']
['great']
['still', 'change', 'used', 'favorite', 'lot', 'categories', 'update', 'example',
['some', 'quizzes', 'crashed', 'everytime', 'i', 'open', 'freeze', 'show', 'nothi
['its', 'good', 'crashes', 'time', 'annoying', 'wouldve', '5', 'stars', 'fixed']
['i', 'understand', 'exists', 'redundant', 'fails', 'load', 'content', 'post', 'c
['amazing', 'app', 'i', 'little', 'trouble', 'polls', 'phone', 'i', 'would', 'lik
['this', 'amazing', 'it', 'favorite', 'search', 'algorithm', 'really', 'bad']
['can', 'please', 'fix', 'fact', 'whole', 'swaths', 'comment', 'sections', 'disap
['its', 'liberal', 'biased', 'i', 'love']
['i', 'loved', 'tbh', 'u', 'wherever', 'u', 'r', '9']
['crashes', 'timr', 'love', 'general']
['it', 'loading', 'news', 'things']
['this', 'free', 'sending', 'notifications', 'nowand', 'starting', 'save', 'stora
['well', 'concettet', 'internet', 'says', 'im', 'concectet']
['just', 'downloaded', 'im', 'reviewing', 'let', 'guys', 'know', 'i', 'cant', 'fi
['good', 'source', 'news', 'way', 'many', 'silly', 'quizzes', 'slog', 'get', 'new
['ok', 'clear', 'options', 'make', 'quizzes', 'all', 'guides', '2014', 'almost',
['amazing', 'app', 'i', 'wish', 'easier', 'find', 'post', 'things', 'i', 'cant',
['i', 'like', 'i', 'wish', 'u', 'could', 'make', 'quizzes', 'articles', 'cause',
['quiiiiizessss']
['love', 'polls', 'part', 'quizzes', 'i', 'choose', 'option', 'pole', 'i', 'cant'
['i', 'heard', 'buzz', 'feed', 'liberal', 'sjw', 'favorite', 'just', 'checking', ['it', 'ok', 'i', 'guess', 'though', 'keep', 'freezing', 'i', 'different', 'artic ['i', 'actually', 'really', 'like', 'would', 'great', 'could', 'get', 'notified',
['i', 'cant', 'login', 'google', 'account', 'i', 'facebook', 'ive', 'issue', 'thc
['i', 'love', 'adds', 'if', 'many', 'adds', 'i', 'would', 'rate', '5', 'stars']
['i', 'liked', 'need', 'wifi', 'love', 'cuz', 'i', 'go', 'want',
                                                                           'play', 'theres'
['hypocritical', 'it', 'allows', 'sponsors', 'gorving', 'homophobic', 'past', 're
['stupid', 'let', 'sign', 'in']
['working', 'wi', 'fi', 'working', 'data', 'network', 'i', 'fix']
['it', 'easy', 'share', 'links', 'social', 'media', 'i', 'spend', 'time', 'deleti
['f', 'you', 'mcvegan', 'finland', 'not', 'sweden']
['there', 'ton', 'bugs']
['love', 'addicting']
['great']
['great']
['still', 'change', 'used', 'favorite', 'lot', 'categories', 'update', 'example',
['some', 'quizzes', 'crashed', 'everytime', 'i', 'open', 'freeze', 'show', 'nothi
 'its', 'good', 'crashes', 'time', 'annoying', 'wouldve', '5', 'stars', 'fixed']
['i', 'understand', 'exists', 'redundant', 'fails', 'load', 'content', 'post', 'c
['amazing', 'app', 'i', 'little', 'trouble', 'polls', 'phone', 'i', 'would', 'lik
['this', 'amazing', 'it', 'favorite', 'search', 'algorithm', 'really', 'bad']
        'please', 'fix', 'fact', 'whole', 'swaths', 'comment', 'sections', 'disap
['its', 'liberal', 'biased', 'i', 'love']
```

```
['i', 'loved', 'tbh', 'u', 'wherever', 'u', 'r', '9']
['crashes', 'timr', 'love', 'general']
['it', 'loading', 'news', 'things']
['this', 'free', 'sending', 'notifications', 'nowand', 'starting', 'save', 'stora
['there', 'are', 'really', 'bad', 'days', 'with', 'the', 'quality', 'of', 'the',
['write', 'well', 'however', 'management', 'reviews', 'are', 'poorly', 'managed',
['the', 'boring', 'admin', 'search', 'is', 'not', 'true', 'news', 'all', 'the', '
['i', 'share', 'the', 'link', 'ko', 'dc']
['very', 'good']
```

Les commentaires sont maintenant unifiés et prêts à être analysés.

Création de corpus

On crée un corpus pour dimunier le temps d'analyse des commentaires (les mots peuvent revenir plusieurs fois dans differents commentaire) :

```
corpus=[]# tous les mots
for comment in data_reviews_light['Translated_Review']:
 comment=comment.lower()
 comment=comment.split()
 for word in comment:
     # print(word)
     corpus.append(word)
corpus_final=[] # mots dans le dictionnaire
for word in corpus:
 if (word in embedding dict):
   corpus final.append(word)
mots_pas_dans_le_dictionnaire = []
for i in corpus :
    if i not in embedding dict:
      mots pas dans le dictionnaire.append(i)
print(len(corpus)) # tous les mots de tous les commentaires
print(len(corpus final)) # mots uniquement dans le dictionnaire
print(len(mots_pas_dans_le_dictionnaire)) # mots pas de le dictionnaire
print(len(mots pas dans le dictionnaire)+len(corpus final)) # mots pas de le dict + mots c
     682235
     669229
     13006
     682235
mots_pas_dans_le_dictionnaire
      'scenerywhen',
      'hahaha',
```

```
'improvement ∅',
'goodbetter',
'perticular',
'bugsused',
'abnb',
'otberwise',
'idk',
'syupid',
'subratings',
'subratings',
'cognation',
'vrbo',
'roomsflats',
'reliase',
'justbe',
'otberwise',
'subratings',
'subratings',
'palarva',
'vrbo',
'redundantalso',
'tripflat',
'pagemost',
'rerate',
'wifes',
'airlineairportdate',
'thinknit',
'thst',
'pointb',
'fibreoptic',
'patienti',
'omgg',
'fricken',
'fricken',
'glidescope',
'controlsthey',
'crazycant',
'carddelete',
'redownloaded',
'akinator',
'akinator',
'freeked',
'creaters',
'catogory',
'lottle',
'tinking',
'dantdm',
'jacksepticeye',
'pewdiepie',
'charecter',
'charecter',
'googleplay',
'akinator',
'akinator',
'geuss',
. . . ]
```

print(corpus_final[17000])

stopped

```
# Sans les mots en doublons
corpus_set = []
for i in corpus_final :
    if i not in corpus_set:
        corpus_set.append(i)

print(len(corpus_set))

17415
```

Fonctions sur les mots

```
def is in positive List(mot):
 for i in range (len(List_Positive_Words)):
    if (mot==List_Positive_Words[i]):
      return True
  return False
def is_in_negative_List(mot):
 for i in range (len(List Negative Words)):
     if (mot==List_Negative_Words[i]):
      return True
  return False
print(is_in_positive_List("great"))
print(is_in_positive_List("storm"))
print(is in negative List("bad"))
print(is in negative List("good"))
     True
     False
     True
     False
Vecteurs des mots:
print(embedding_dict[List_Positive_Words[2]])
     [-4.5233e-01 5.2751e-01 7.3868e-01 1.5545e-01 -2.3743e-01 -3.8078e-01
     -8.1186e-01 5.6340e-02 -4.6594e-01 -2.3452e-01 -6.0791e-01 1.2848e-01
       8.8493e-02 -5.3156e-01 3.6207e-01 -4.6797e-01 -4.8562e-02 2.5927e-01
      -1.3124e-01 3.6245e-01 -4.1970e-01 1.1485e-01 -1.0726e-01 -1.1621e-01
      3.2918e-01 6.0528e-01 4.9863e-01 -6.1456e-02 -7.1600e-01 -3.9398e-01
      -1.2088e-01 -4.7428e-01 -3.2745e-01 4.8528e-04 3.2447e-01 -2.2450e-02
       3.5431e-01 3.5650e-01 -2.3936e-01 -6.5994e-01 1.8976e-01 -1.6451e-01
```

```
-4.7788e-01 -1.2073e-01 5.9554e-01 -4.2042e-01 -5.4063e-03 2.1056e-01
    -5.0805e-02 -1.6569e-01 3.1778e-01 -3.8782e-02 1.1279e-01 4.2791e-01
     3.9531e-01 -6.9410e-01 -1.1811e-01 -6.2810e-01 2.7714e-01 -4.4773e-01
    -5.6234e-01 2.7331e-01 7.8971e-02 5.9745e-03 1.2053e+00 -3.4645e-01
     6.8173e-01 -1.4753e+00 1.0289e+00 -2.1376e-01 -1.3246e-03 2.3337e-02
     6.1387e-01 5.4320e-02 4.2838e-01 5.4175e-01 -1.8819e-01 -8.8571e-01
    -2.5535e-01 3.5455e-01 3.8472e-02 4.4128e-02 -4.4493e-01 -1.4141e-01
     1.1764e-01 -2.6306e-01 7.6187e-01 -5.6519e-01 -5.5019e-01 7.2612e-02
    -1.5094e-02 -2.4337e-01 -1.5258e-01 -8.5876e-03 -6.5707e-01 -7.6442e-01
    -1.1081e+00 -8.4819e-01 2.8330e-01 3.1045e-01]
embedding dict["happy"]
    array([-0.090436 , 0.19636 , 0.29474 , -0.47706 , -0.80436
          0.3078 , -0.55205 , 0.58453 , -0.17056 , -0.84846 ,
          0.19528 , 0.23671 , 0.46827 , -0.58977 , -0.12163
         -0.24697 , -0.072944 , 0.17259 , -0.0485 , 0.9527
          0.50629 , 0.58497 , -0.19367 , -0.45459 , -0.031095 ,
          0.51633 , -0.24052 , -0.1007
                                    , 0.53627 , 0.024225 ,
                                              , 0.89337
         -0.50162
                 , 0.73692 , 0.49468 , -0.34744
          0.057439 , -0.19127 , 0.39333 , 0.21182 , -0.89837
          0.078704 , -0.16344 , 0.45261 , -0.41096 , -0.19499
         -0.13489 , -0.016313 , -0.021849 , 0.17136 , -1.2413
                                              , -0.24934
          0.079503 , -0.91144 , 0.35699 , 0.36289
         -2.1196 , 0.14534 , 0.52964 , 0.90134 , 0.033603 ,
          0.022809 , 0.70625 , -1.0362 , -0.59809 , 0.70592 ,
         -0.072793 , 0.67033 , 0.52763 , -0.47807 , -0.67374
                                             , 0.18104
          0.36632 , -0.38284 , -0.10349 , -0.6402
          0.82568 , 0.066403 , -0.40791 , -0.083813 , -0.36487
          0.045362 , -0.073527 , -0.20117 , 0.37441 , -1.4024
         -0.25605 , -0.4708 , -0.16145 , -0.87921 , -0.36325
         -0.17357
                 , -0.077983 , 0.43273 , 0.0089295, -1.0316
         -0.11589 , -0.34524 , 0.11514 , -0.40812 , 0.20203 ],
        dtype=float32)
embedding_dict["best"] - embedding_dict["best"]
    dtype=float32)
Fonctions sur les vecteurs de mots :
def similarite(mot1, mot2):
 ScoreS=100
 m=embedding dict[mot1]-embedding dict[mot2]
 for i in range(100):
   if (m[i]<0):
    m[i] = -m[i] #on convertit les vecteurs (float) negatifs en positifs.
   ScoreS=ScoreS-m[i]
```

print("La différence des vecteurs : \n",m)

```
# print("Taux de similarité en %: ",ScoreS)
  return ScoreS
similarite("best", "good")
     70.38544163107872
similarite("ketchup", "good")
     39.91801256686449
similarite("storm", "good")
     45.845109801739454
similarite("storm", "bad")
     52.51504706311971
similarite("computer", "science")
     53.163571901619434
similarite("cat", "dog")
     79.31042091920972
```

Fonctions de score de ressemblance avec les mots positifs et negatifs des listes prédéfinies :

```
def score_positivity(mot):
  scoreP=0
  for i in range (len(List Positive Words)):
   value = similarite(mot,List_Positive_Words[i])
    if (scoreP < value):</pre>
      scoreP=value
      word= List Positive Words[i]
  return scoreP
def score_negativity(mot):
  scoreN=0
  for i in range (len(List Negative Words)):
   value = similarite(mot,List Negative Words[i])
    if (scoreN < value):</pre>
      scoreN=value
      word= List Negative Words[i]
  return scoreN
```

```
score negativity("crazy")
     100.0
score_positivity("mother")
     65.73830030485988
score_positivity("father")
     63.249436780810356
score positivity("teacher")
     60.93676929175854
Match du mot parmi ceux positifs ou ceux negatifs ayant le plus d'affinités :
def positive_word_match(mot):
  scoreN=0
  for i in range (len(List_Positive_Words)):
    value = similarite(mot,List_Positive_Words[i])
    if (scoreN < value):</pre>
      scoreN=value
      word= List_Positive_Words[i]
  return word
def negative_word_match(mot):
  scoreN=0
  for i in range (len(List_Negative_Words)):
   value = similarite(mot,List_Negative_Words[i])
    if (scoreN < value):</pre>
      scoreN=value
      word= List_Negative_Words[i]
  return word
negative_word_match("good")
     'bad'
Fonctions qui renvoient le match et le score du match :
def negative_word_match_and_score(mot):
  scoreN=0
  for i in range (len(List Negative Words)):
    value = similarite(mot,List_Negative_Words[i])
    if (scoreN < value):</pre>
```

```
scoreN=value
      word= List Negative Words[i]
  result=['1','2']
  result[0]=word
  result[1]=scoreN
  return result
def positive_word_match_and_score(mot):
  scoreN=0
  for i in range (len(List_Positive_Words)):
   value = similarite(mot,List_Positive_Words[i])
    if (scoreN < value):</pre>
      scoreN=value
      word= List_Positive_Words[i]
  result=['1','2']
  result[0]=word
  result[1]=scoreN
  return result
negative word match and score("agree")
     ['reject', 72.79815086349845]
negative_word_match_and_score("better")
     ['bad', 70.36610453948379]
negative_word_match_and_score("ketchup")
     ['mashed', 59.4631655625999]
```

En utilisant les fonctions précédentes : plusieurs moyens pour calculer le score d'un mot. En effet, il a fallu en tester plusieurs car le temps d'execution étant très long pour le corpus entier, il faut trouver le meilleur compromis

```
def score_one_word(mot):
    positivity=score_positivity(mot)
    negativity=score_negativity(mot)
    if (negativity<positivity):
        return positivity
    else:
        return -negativity</pre>
score_one_word("car")
-59.1006375849247
```

```
score_one_word("light")
     66.5369235817343
score_one_word("president")
     -68.66725947335362
def score_one_word_neutral(mot):
  positivity=score_positivity(mot)
  negativity=score_negativity(mot)
  return (positivity-negativity)/100
score_one_word_neutral("morning")
     0.07072803180664777
score_one_word_neutral("pop")
     -0.009208365716040135
def score_one_word_short(mot):
  positivity=similarite(mot, "positive")
  negativity=similarite(mot, "negative")
  return positivity-negativity
score_one_word_short("morning")
     1.6712139397859573
score_one_word_short("pop")
     -2.3921898752450943
même si short est peu couteuse, les resultats ont moins de sens
on gardera score one word neutral
```

CALCUL positivité d'un mot

avec une fonction

```
# liste light=[]
```

```
# for word in corpus set:
 # if (word not in List_Positive_Words) and (word not in List_Negative_Words):
    # liste light.append(word)
# len(liste_light)
____ 6 heures d'execution donc laissez les en commentaire
# liste=[]
# for i in corpus_set:
  # liste.append(score_one_word_neutral(i))
# len(liste)
# len(corpus_set)
# for a in range(len(liste)):
  # liste[a]=liste[a]/100
# print(liste)
# print(corpus_set)
# liste_vraie=[]
# i=0
# for word in corpus_set:
  liste_vraie.append(word)
  i=i+1
  if (i==8577):
    break
# len(liste vraie)
# df = pd.DataFrame (data, columns = ['word', 'score'])
# print(df)
# data = {'word': corpus set, 'score': liste}
# output = pd.DataFrame(df)
# output.to csv('/content/drive/My Drive/kaggle/playstore/word in corpus corpus score.csv'
# print("Your submission was successfully saved!")
df = pd.read_csv("/content/drive/My Drive/kaggle/playstore/word_in_corpus_corpus_score_1.c
```

/usr/local/lih/nython3 6/dist_nackages/seahorn/distributions nv:2557. FutureWarning.

avec une random forest

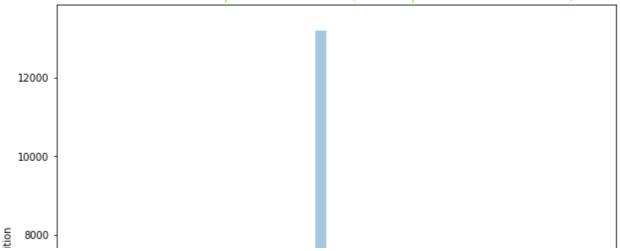
```
comme la fonction met trop de temps à s'executer on teste le calcul avec une Random Forest
vecteur={}
for i in range(100):
vecteur["vec_%s"% str(i)] = []
print(vecteur['vec_0'])
     word_d=[]
score_d=[]
for i in range(4000):
 mot d=df2.word[i]
 word_d.append(mot_d)
 score_d.append(int(df2.score[i]))
 for i in range(100):
   vecteur["vec_%s"% str(i)].append(embedding_dict[mot_d][i])
# Verification
print(len(word_d))
print(len(vecteur['vec 10']))
print(len(vecteur['vec_0']))
     4000
     4000
     4000
data_d={'word': word_d, 'score': score_d}
for i in range(100):
 data d["vec %s"% str(i)]=vecteur["vec %s"% str(i)]
train d = pd.DataFrame (data d)
# train_d = train_d.sort_values(by = 'word')
print(train d)
                              vec 0 ... vec 97
                                                      vec 98 vec 99
                word score
     0
                          6 -0.046539 ... -0.376160 -0.032502 0.80620
     1
                          2 -0.794350 ... -0.323350 0.698980 0.26452
                eat
     2
                food
                          0 -0.164860
                                       ... -0.067904
                                                     1.507200 0.60889
     3
              thats
                          0 0.197900 ... -0.271500 -0.616550 0.67307
                        -2 0.417110 ... -0.294440 -0.039114 0.39534
                 im
                                                 . . .
                 . . .
                        . . .
                                                           . . .
                        -1 0.228510
                                      ... -0.148570 0.567130 0.97960
     3995
            argument
     3996
                        0 0.161920 ... -0.216530 -0.277120 0.14191
                 bod
     3997
              solved
                        -3 -0.143480 ... -0.334170 0.105990 -0.12502
                         -6 0.867620 ...
                                           0.390640 -0.021307
                                                               0.10499
     3998
          admitting
     3999
            teacher
                         3 0.443740 ... -0.665220 -0.100120 -0.17729
```

```
[4000 rows x 102 columns]
# output donc consultable sur le drive
train_d.to_csv('/content/drive/My Drive/kaggle/data_vec_positivity.csv', index=False)
le train est bien correct
maintenant on prépare le test
vecteur_f={}
for i in range(100):
vecteur_f["vec_%s"% str(i)] = []
print(vecteur_f["vec_15"])
    corpus_rf=[]
for word in corpus_set:
 if (word not in List_Positive_Words or word not in List_Negative_Words):
   corpus_rf.append(word)
word_f=[]
for word in corpus rf:
 word_f.append(word)
 for i in range(100):
   vecteur f["vec %s"% str(i)].append(embedding dict[word][i])
data_f={'word': word_f}
for i in range(100):
 data_f["vec_%s"% str(i)]=vecteur_f["vec_%s"% str(i)]
test_f = pd.DataFrame (data_f)
# test_f =test_f.sort_values(by = 'word')
print(test f)
                word
                       vec_0
                                 vec_1 ... vec_97 vec_98 vec_99
                  1
                like -0.268700 0.817080 ... -0.401100 0.746570 0.31122
                 eat -0.794350 0.732210 ... -0.323350 0.698980 0.26452
    3
           delicious -0.655340 0.340340 ... -0.688530 0.089564 0.72300
                food -0.164860 0.919970 ... -0.067904 1.507200 0.60889
                      . . .
                                    . . .
    17410 predefined -0.623740 0.008601 ... -0.266930 -0.337900 0.65559
             luxury 0.044913 -0.025096 ... -0.229930 2.082600 -0.20064
    17411
    17412
               flats 0.234120 0.258010 ... -0.166650 0.280700 -0.23462
    17413 rigorously -0.566620 0.038456 ... -0.257400 -0.408960 0.45789
    17414
          reachable -0.998720 -0.081571 ... 0.112860 -0.045551 -0.10090
    [17415 rows x 101 columns]
features=[]
for i in range(100):
 fastures annead("vec %c"% str(i))
```

```
icarnico.appenní ver 100 % ori (1))
y = train d['score']
X = pd.get dummies(train d[features])
X_test = pd.get_dummies(test_f[features])
model = RandomForestClassifier(n_estimators=100, max_depth=100, random_state=1)
model.fit(X, y)
predictions = model.predict(X_test)
output = pd.DataFrame({'word': test_f.word, 'score': predictions})
print(output)
                word score
                   i 6
    1
                 like
                 eat
          delicious
     3
                         0
                food
                 . . .
    17410 predefined
                         0
    17411
              luxury
    17412
               flats
    17413 rigorously
                         0
    17414 reachable
    [17415 rows x 2 columns]
plt.figure(figsize=(10, 10))
dist = sns.distplot(output.score, kde=False)
dist.set_xlabel("Polarité")
dist.set_ylabel("nombre d'apparition")
plt.title('Distribution de la polarité des mots (calculé par une random forest)', size = 14
```

/usr/local/lib/python3.6/dist-packages/seaborn/distributions.py:2557: FutureWarning: `distplot` is a deprecated function and will be removed in a future version. Please Text(0.5, 1.0, 'Distribution de la polarité des mots (calculé par une random forest)

Distribution de la polarité des mots (calculé par une random forest)



La random forest est plus efficace, on calcule beaucoup plus vite

ē |

SCORE D'UN REVIEWS :

Tri data:

data_test_polarity=data_reviews_light.copy()
data_test_polarity=data_test_polarity.drop(['Sentiment_Polarity'], axis=1)
data_test_polarity.head()

Translated_Review

- I like eat delicious food Thats Im cooking foo...
- 1 This help eating healthy exercise regular basis
- 3 Works great especially going grocery store
- 4 Best idea us
- 5 Best way

Methode 1

```
très longue
```

```
def score(review):
   Tableau=[]
   Tableau=review.split()
```

```
scoreP=0
  scoreN=0
  scoreA=0
  Nb mots non liste=0
  for i in range(len(Tableau)):
    print(Tableau[i])
    Tableau[i] = Tableau[i].lower() # on met le mot en minuscule
    if (is_in_positive_List(Tableau[i])):
      scoreP=scoreP+1 #si la review contient un mot positif le scoreP s'incrémente
    elif (is_in_negative_List(Tableau[i])):
      scoreN=scoreN-1 #si la review contient un mot positif le scoreN s'incrémente
    else:
      scoreA=scoreA+score_one_word(Tableau[i])
      Nb mots non liste=Nb mots non liste+1
      scoreA=scoreA/Nb_mots_non_liste
      scoreA=scoreA/100
  return (scoreP, scoreN, scoreA)
score("hello les animaux")
# Exemple
     hello
     les
     animaux
     (0, 0, -0.2540823391545756)
score(data_reviews_light['Translated_Review'][5])
     Best
     way
     (1, 0, 0.75478557119146)
```

methode 2

Methode 2 Neutral score: pas trop retenu car peu de sens

```
def score_neutral(review):
   Tableau=[]
   Tableau=review.split()
   scoreP=0
   scoreN=0
   scoreA=0
   ScoreT=0
   Nb_mots_non_liste=0
   for i in range(len(Tableau)):
```

```
Tableau[i]= Tableau[i].lower()
# print(Tableau[i])

for word in embedding_dict:
    if (word==Tableau[i]):
        if (is_in_positive_List(Tableau[i])):
            scoreP=scoreP+1 #si la review contient un mot positif le scoreP s'incrémente

    elif (is_in_negative_List(Tableau[i])):
        scoreN=scoreN-1 #si la review contient un mot positif le scoreN s'incrémente

    else:
        scoreA=scoreA+score_one_word(Tableau[i])
        scoreA=scoreA/100
        scoreA=scoreA/100
        scoreT=(scoreP+scoreN+scoreA)/len(Tableau)
```

methode 3

Methode 3: en utilisant le corpus et la new_liste avec les scores

```
def score_best_method(review):
  Tableau=[]
 Tableau=review.split()
  scoreP=0
  scoreW=0
  Nb_words=0
  for w in Tableau:
   w= w.lower()
    if (w in corpus set):
      i=corpus set.index(w)
      scoreW=df["score"][i]
      if (scoreW==1 or scoreW==-1):
        scoreW=scoreW*2
        Nb_words=Nb_words+2
      else:
        Nb words=Nb words+1
      scoreP= (scoreP+scoreW)/Nb words
  # ScoreT=(scoreP+scoreN+scoreA)/len(Tableau)
  return (scoreP)
```

Utilisation de la méthode 3

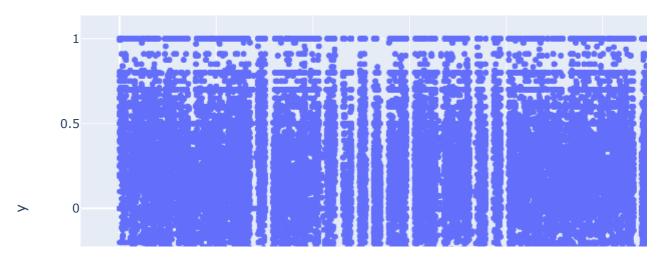
On calcule le score de chaque reviews en s'appuyant des mots qui la composent

```
data_score_review=[]
i=0
for review in data_test_polarity.Translated_Review:
    # print(review)
    data_score_review.append(score_best_method(review))
    i=i+1
    # if (i==5):
        # break
print(data_score_review)

    [0.0013038548235165788, 0.004381178954697493, 0.019443023269194077, 0.06329578371330

print(len(data_test_polarity.Translated_Review))
        37427
```

Visualisation polarité



```
# la polarité des commentaires de la data
plt.figure(figsize=(15, 10))
dist = sns.distplot(a=data_reviews['Sentiment_Polarity'], kde=False)
dist.set_xlabel("Polarité")
dist.set_ylabel("index")
plt.title('Distribution de la polarité', size = 25, color='grey')
```

/usr/local/lib/python3.6/dist-packages/seaborn/distributions.py:2557: FutureWarning: `distplot` is a deprecated function and will be removed in a future version. Please Text(0.5, 1.0, 'Distribution de la polarité')

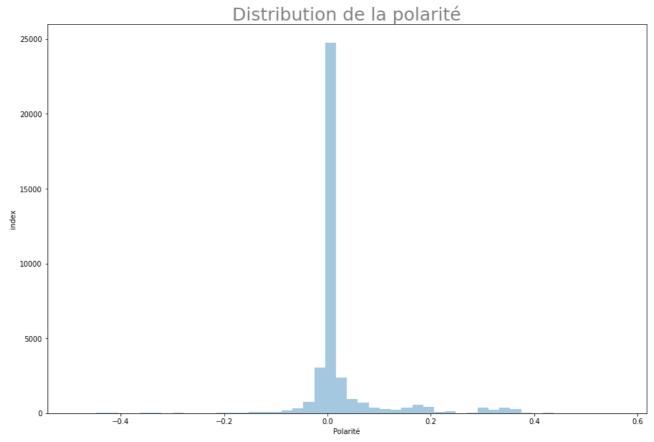
Distribution de la polarité

```
# la polarité des commentaires de la data qu'on a predit
plt.figure(figsize=(15, 10))
dist = sns.distplot(a=data_score_review, kde=False)
dist.set_xlabel("Polarité")
dist.set_ylabel("index")
plt.title('Distribution de la polarité',size = 25, color='grey')
```

 $/usr/local/lib/python 3.6/dist-packages/seaborn/distributions.py: 2557:\ Future Warning: 1.00 and 1.$

`distplot` is a deprecated function and will be removed in a future version. Please

Text(0.5, 1.0, 'Distribution de la polarité')



NUAGES DE TAGS

Création des textes "mots des titres" par Catégorie

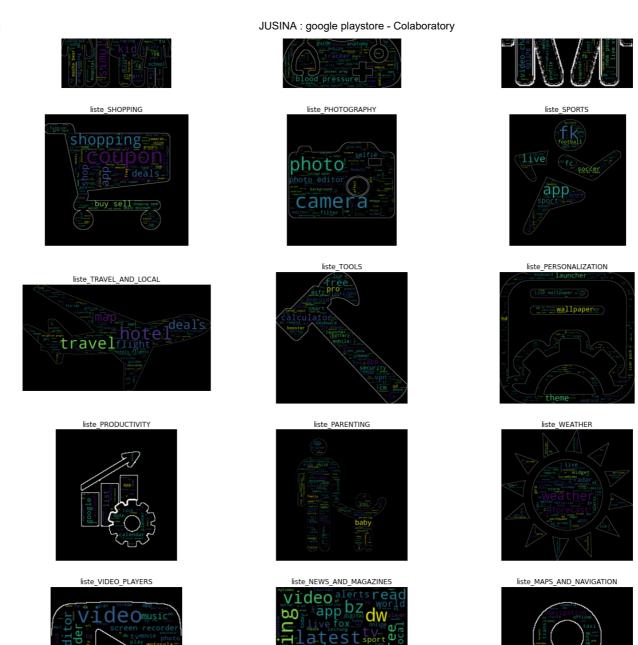
```
titres_applis=[]
titres_applis = data_reviews['App'].unique()
print(titres_applis)
print(len(titres_applis))
     ['10 Best Foods for You' '104 找工作 - 找工作 找打工 找兼職 履歷健檢 履歷診療室' '11st'
      'Hotwire Hotel & Car Rental App' 'Housing-Real Estate & Property'
      'Houzz Interior Design Ideas']
     1074
liste titres={}
for cat in category:
    liste_titres["liste_%s"% str(cat)] = ['hey','h']
print (liste_titres['liste_ART_AND_DESIGN'])
print (liste_titres)
     ['hey', 'h']
     {'liste_ART_AND_DESIGN': ['hey', 'h'], 'liste_AUTO_AND_VEHICLES': ['hey', 'h'], 'lis
liste titres={}
for cat in category:
  liste_mots_titre=[]
  for i in data.index:
    if data['Category'][i]==cat:
     title=data["App"][i]
      title=title.lower()
      title=title.split()
      for i in range(len(title)):
       word=title[i]
        liste mots titre.append(word)
  StrA = " ".join(liste_mots_titre)
    # if name not in liste titres:
      # liste titres.append(name.split())
  # data_titres_tries.cat[i]=[liste_titres]
  # data_titres_tries[i] = liste_titres
  liste titres["liste %s"% str(cat)] = StrA
liste_titres['liste_ART_AND_DESIGN']
```

'photo editor & candy camera & grid & scrapbook coloring book moana u launcher lite – free live cool themes, hide apps sketch - draw & paint pixel draw - number art co loring book paper flowers instructions smoke effect photo maker - smoke editor infi nite painter garden coloring book kids paint free - drawing fun text on photo - fon

Dessins Nuages de tags

```
# import
from PIL import Image
WC = \{ \}
for cat in category:
 a = '/content/drive/My Drive/kaggle/playstore/images/%s'% str(cat)
 b = '/content/drive/My Drive/kaggle/playstore/images/Tags/%s'% str(cat)
 image = np.array(Image.open(a + '.png'))
 wc["liste_%s"% str(cat)]=WordCloud(background_color="black", mask=image, contour_width=1
 wc["liste_%s"% str(cat)].generate(liste_titres["liste_%s"% str(cat)])
 wc["liste_%s"% str(cat)].to_file(b + '.png')
plt.figure(figsize=(20,60))
for 1 in liste_titres:
 i=i+1
 plt.subplot(12,3,i)
 plt.imshow(wc[1], interpolation='bilinear')
 plt.title(1)
 plt.axis("off")
```





Prédiction de la catégorie

player

```
# On recupere les mots de chaque titre
all_words_titres=[]
for h in liste_titres:
    liste=liste_titres[h].translate(str.maketrans('', '', string.punctuation))
    liste=liste.lower()
    liste=liste.split()
    for word in liste:
        if word not in all_words_titres:
            all_words_titres.append(word)
```

```
['photo', 'editor', 'candy', 'camera', 'grid', 'scrapbook', 'coloring', 'book', 'moa
# dictionnaire des frequences
fq={}
for cat in category:
 fq[cat]=[]
l=['bonjour', 'je', 'mappelle', 'simon']
m=Counter(1)
print(m)
     Counter({'bonjour': 1, 'je': 1, 'mappelle': 1, 'simon': 1})
liste titres["liste GAME"]
     'roblox subway surfers candy crush saga solitaire bubble shooter hello kitty nail s
     alon slither.io clash royale temple run 2 pou helix jump block puzzle angry birds r
     io plants vs. zombies free sonic dash candy crush soda saga zombie hunter king clas
    h of clans kick the buddy block puzzle classic legend ! pac-man super jim jump - pi
    xel 3d 8 ball pool magic tiles 3 bubble witch 3 saga word search granny angry birds
     classic flow free race the traffic moto fishdom galaxy attack: alien shooter zombie
    tsunami bubble shooter 2 barbie™ fashion closet candy crush jelly saga hill climb r
     acing gardenscapes marble - temple quest shooting king zombie catchers minion rush:
    despicable me official game farm heroes saga geometry dash world my talking angela
     cut the rope full free sniper 3d gun shooter: free shooting games - fps subway surf
    ers roblox pou 8 ball pool clash of clans candy crush saga plants vs. zombies free
for cat in category:
 # on enleve la ponctuation
 liste_titres["liste_%s"% str(cat)]=liste_titres["liste_%s"% str(cat)].translate(str.make
 # tout en minuscule
 liste titres["liste %s"% str(cat)]=liste titres["liste %s"% str(cat)].lower()
 liste titres["liste %s"% str(cat)]=liste titres["liste %s"% str(cat)].split()
for cat in category:
 m=Counter(liste titres["liste %s"% str(cat)])
 for word in all words titres:
    if word in m:
      fq[cat].append(1-1/m[word]) #normalisation
    else: fq[cat].append(0)
len(fq['LIFESTYLE'])
     9455
len(all_words_titres)
     9455
```

```
for cat in category:
    data_t[cat]=fq[cat]

data_fréquence = pd.DataFrame (data_t)
data_fréquence = data_fréquence.sort_values(by = 'mot')
data_fréquence.to_csv('/content/drive/My_Drive/kaggle/data_fréquence.csv', index=False)
```

data_fréquence.head()

creation du train pour la random forest

	mot	ART_AND_DESIGN	AUTO_AND_VEHICLES	BEAUTY	BOOKS_AND_REFERENCE	BUSINES
186	02	0.0	0.0	0.0	0.000000	0
9207	058ba	0.0	0.0	0.0	0.000000	0
678	1	0.0	0.0	0.0	0.666667	0
1822	10	0.0	0.0	0.0	0.000000	0
5187	100	0.0	0.0	0.0	0.000000	0

```
category_word=[]
word=[]
ma_cat=''
for i in data fréquence.index:
  if data_fréquence.mot[i] in embedding_dict:
    word.append(data_fréquence.mot[i])
    score=0
    for cat in category:
      valeur=data_fréquence["%s"% str(cat)][i]
      if (score < valeur):</pre>
        score=valeur
        ma cat=cat
    category_word.append(ma_cat)
data_last_one={'word' : word ,'Best_Category': category_word}
vecteur_last_one={}
for i in range(100):
 vecteur_last_one["vec_%s"% str(i)] = []
for w in word:
  for i in range(100):
    vecteur_last_one["vec_%s"% str(i)].append(embedding_dict[w][i])
for i in range(100):
 data_last_one["vec_%s"% str(i)] = vecteur_last_one["vec_%s"% str(i)]
data catagony - nd DataEnamo (data last one)
```

```
JUSINA: google playstore - Colaboratory
uata_category = pu.vatarrame (uata_tast_one)
data category.head()
data_category.to_csv('/content/drive/My Drive/kaggle/data_category.csv', index=False)
def creation df(liste):
 liste=liste.lower()
 liste=liste.split()
 words_list_in_dict=[]
 vecteurs={}
 for i in range(100):
   vecteurs["vec_%s"% str(i)] = []
 for w in liste:
   if w in embedding_dict:
     words list in dict.append(w)
     for i in range(100):
       vecteurs["vec_%s"% str(i)].append(embedding_dict[w][i])
 data_p={'word': words_list_in_dict}
 for i in range(100):
   data_p["vec_%s"% str(i)]=vecteurs["vec_%s"% str(i)]
 data_predict = pd.DataFrame (data_p)
 return data_predict
# test
creation_df('good morning')
                    vec_0
                             vec_1
                                       vec_2
                                                 vec_3
           word
                                                          vec_4
                                                                   vec_5
                                                                             vec_6
                                                                                      vec
      0
                -0.030769
                            -0.15345
                                                                          0.081126
                                                                                    -0.385
           good
      1 morning
                -0.210040 -0.39664 0.009014 -0.025219 -0.58011
                                                                 0.39678 0.389730
                                                                                     1.113
     2 rows × 101 columns
def predict category(titre):
 data predict = creation df(titre)
 y = data category['Best Category']
 features=[]
 for i in range(100):
   features.append("vec_%s"% str(i))
 X = pd.get dummies(data category[features])
 X_test = pd.get_dummies(data_predict[features])
```